SQL - Funkcje okna (Window functions)
Lab 1

Imiona i nazwiska: Natalia Bratek, Jakub Karczewski

Celem ćwiczenia jest przygotowanie środowiska pracy, wstępne zapoznanie się z działaniem funkcji okna (window functions) w SQL, analiza wydajności zapytań i porównanie z rozwiązaniami przy wykorzystaniu "tradycyjnych" konstrukcji SQL

Swoje odpowiedzi wpisuj w miejsca oznaczone jako:

> Wyniki:

```
-- ...
```

Ważne/wymagane są komentarze.

Zamieść kod rozwiązania oraz zrzuty ekranu pokazujące wyniki, (dołącz kod rozwiązania w formie tekstowej/źródłowej)

Zwróć uwagę na formatowanie kodu

Oprogramowanie - co jest potrzebne?

Do wykonania ćwiczenia potrzebne jest następujące oprogramowanie:

- MS SQL Server - wersja 2019, 2022, 2025
- PostgreSQL - wersja 15/16/17/18
- SQLite
- Narzędzia do komunikacji z bazą danych
    - SSMS - Microsoft SQL Managment Studio
    - DtataGrip lub DBeaver
- Przykładowa baza Northwind
    - W wersji dla każdego z wymienionych serwerów

Oprogramowanie dostępne jest na przygotowanej maszynie wirtualnej

Dokumentacja/Literatura

- Kathi Kellenberger, Clayton Groom, Ed Pollack, Expert T-SQL Window Functions in SQL Server 2019, Apres 2019

- Itzik Ben-Gan, T-SQL Window Functions: For Data Analysis and Beyond, Microsoft 2020

- Kilka linków do materiałów które mogą być pomocne - https://learn.microsoft.com/en-us/sql/t-sql/queries/select-over-clause-transact-sql?view=sql-server-ver16
    - https://www.sqlservertutorial.net/sql-server-window-functions/
    - https://www.sqlshack.com/use-window-functions-sql-server/
    - https://www.postgresql.org/docs/current/tutorial-window.html
    - https://www.postgresqltutorial.com/postgresql-window-function/
    - https://www.sqlite.org/windowfunctions.html
    - https://www.sqlitetutorial.net/sqlite-window-functions/
- W razie potrzeby - opis Ikonek używanych w graficznej prezentacji planu zapytania w SSMS jest tutaj:
    - https://docs.microsoft.com/en-us/sql/relational-databases/showplan-logical-and-physical-operators-reference

Przygotowanie

Uruchom SSMS - Skonfiguruj połączenie z bazą Northwind na lokalnym serwerze MS SQL

Uruchom DataGrip (lub Dbeaver)

- Skonfiguruj połączenia z bazą Northwind3
    - na lokalnym serwerze MS SQL
    - na lokalnym serwerze PostgreSQL
    - z lokalną bazą SQLite

Zadanie 1 - obserwacja

Wykonaj i porównaj wyniki następujących poleceń.

```
select avg(unitprice) avgprice
from products p;

select avg(unitprice) over () as avgprice
from products p;

select categoryid, avg(unitprice) avgprice
from products p
group by categoryid

select avg(unitprice) over (partition by categoryid) as avgprice
from products p;
```

Jaka jest są podobieństwa, jakie różnice pomiędzy grupowaniem danych a działaniem funkcji okna?

> Wyniki:

100 %

Results | Messages

	avgprice
1	28,8663

Results | Messages

	avgprice
1	28,8663
2	28,8663
3	28,8663
4	28,8663
5	28,8663
6	28,8663
7	28,8663
8	28,8663
9	28,8663
10	28,8663
11	28,8663

100 %

Results | Messages

	categoryid	avgprice
1	1	37,9791
2	2	23,0625
3	3	25,16
4	4	28,73
5	5	20,25
6	6	54,0066
7	7	32,37
8	8	20,6825

100 %

Results | Messages

	avgprice
1	37,9791
2	37,9791
3	37,9791
4	37,9791
5	37,9791
6	37,9791
7	37,9791
8	37,9791
9	37,9791
10	37,9791
11	37,9791
12	37,9791
13	23,0625
14	23,0625
15	23,0625
16	23,0625
17	23,0625
18	23,0625
19	23,0625
20	23,0625
21	23,0625
22	23,0625
23	23,0625
24	23,0625

- podobieństwa: funkcja okna i grupowanie dają takie same wyniki dla średniej ceny kategorii i produktów
- różnice: grupowanie zwraca jeden wynik dla każdej grupy, a funkcja okna zwraca wszytskie rekordy razem z obliczonym wynikiem

---

Zadanie 2 - obserwacja

Wykonaj i porównaj wyniki następujących poleceń.

```
--1)

select p.productid, p.ProductName, p.unitprice,
       (select avg(unitprice) from products) as avgprice
from products p
where productid < 10

--2)
select p.productid, p.ProductName, p.unitprice,
       avg(unitprice) over () as avgprice
from products p
where productid < 10
```

Jaka jest różnica? Czego dotyczy warunek w każdym z przypadków? Napisz polecenie równoważne

- 1. z wykorzystaniem funkcji okna. Napisz polecenie równoważne
- 2. z wykorzystaniem podzapytania

> Wyniki:

100 %

Results | Messages

	productid	ProductName	unitprice	avgprice
1	1	Chai	18,00	28,8663
2	2	Chang	19,00	28,8663
3	3	Aniseed Syrup	10,00	28,8663
4	4	Chef Anton's Cajun Seasoning	22,00	28,8663
5	5	Chef Anton's Gumbo Mix	21,35	28,8663
6	6	Grandma's Boysenberry Spread	25,00	28,8663
7	7	Uncle Bob's Organic Dried Pears	30,00	28,8663
8	8	Northwoods Cranberry Sauce	40,00	28,8663
9	9	Mishi Kobe Niku	97,00	28,8663

100 %

Results | Messages

	productid	ProductName	unitprice	avgprice
1	1	Chai	18,00	31,3722
2	2	Chang	19,00	31,3722
3	3	Aniseed Syrup	10,00	31,3722
4	4	Chef Anton's Cajun Seasoning	22,00	31,3722
5	5	Chef Anton's Gumbo Mix	21,35	31,3722
6	6	Grandma's Boysenberry Spread	25,00	31,3722
7	7	Uncle Bob's Organic Dried Pears	30,00	31,3722
8	8	Northwoods Cranberry Sauce	40,00	31,3722
9	9	Mishi Kobe Niku	97,00	31,3722

Query executed successfully. LAPTOP-LLFF3LOJ\AGH (15.0

Różnica: w pierwszym zapytaniu jest średnia wszystkich produktów, a w drugim zapytaniu średnia cena produktów o productid < 10

- funkcja okna

```
select p.productid, p.ProductName, p.unitprice,
       avg(p.unitprice) over () as avgprice
from products p
where productid < 10;
```

- podzapytanie

```
select p.productid, p.ProductName, p.unitprice,
       (select avg(unitprice) from products) as avgprice
from products p
where productid < 10;
```

W funkcji okna średnia liczona jest tylko dla przefiltrowanych danych, w podzapytaniu średnia jest liczona dla całej tabeli.

Zadanie 3

Baza: Northwind, tabela: products

Napisz polecenie, które zwraca: id produktu, nazwę produktu, cenę produktu, średnią cenę wszystkich produktów.

Napisz polecenie z wykorzystaniem z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

W SSMS włącz dwie opcje: Include Actual Execution Plan oraz Include Live Query Statistics

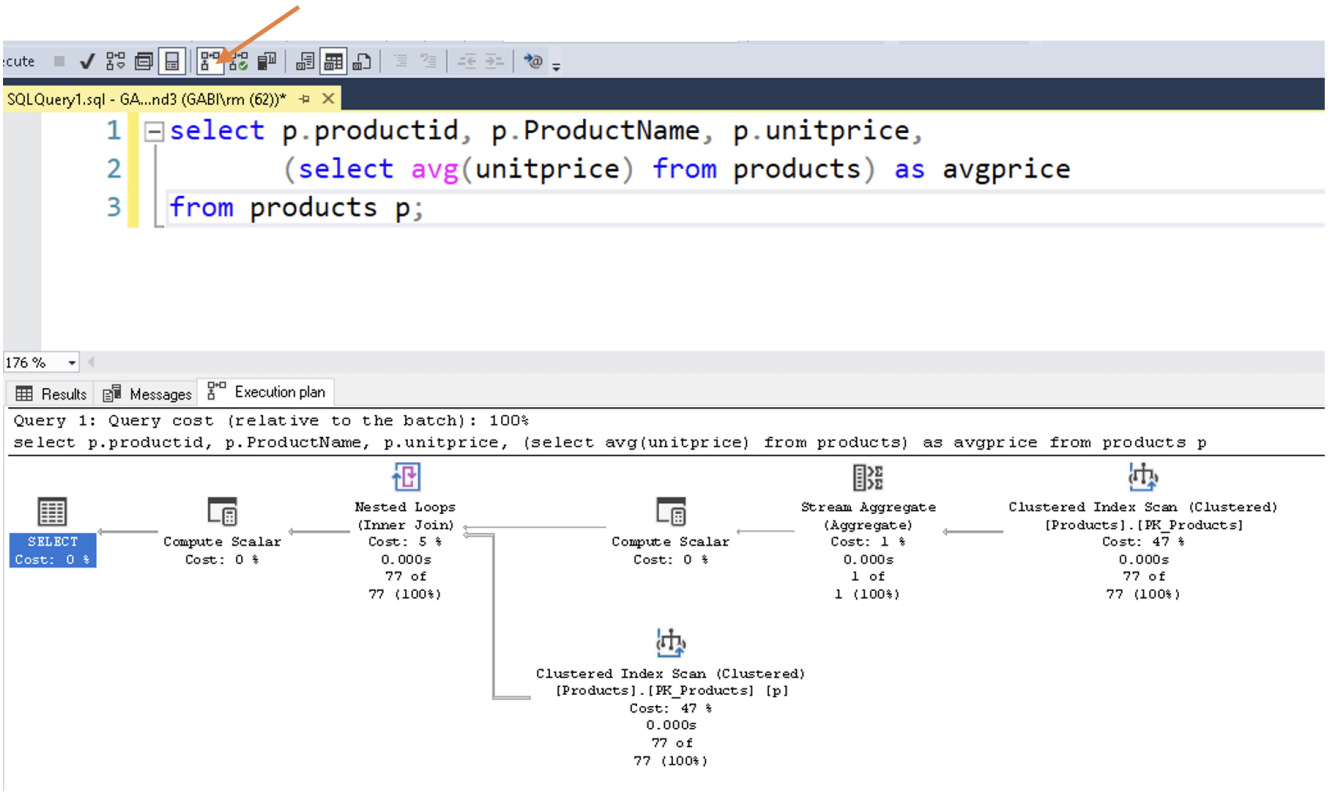

W DataGrip użyj opcji Explain Plan/Explain Analyze

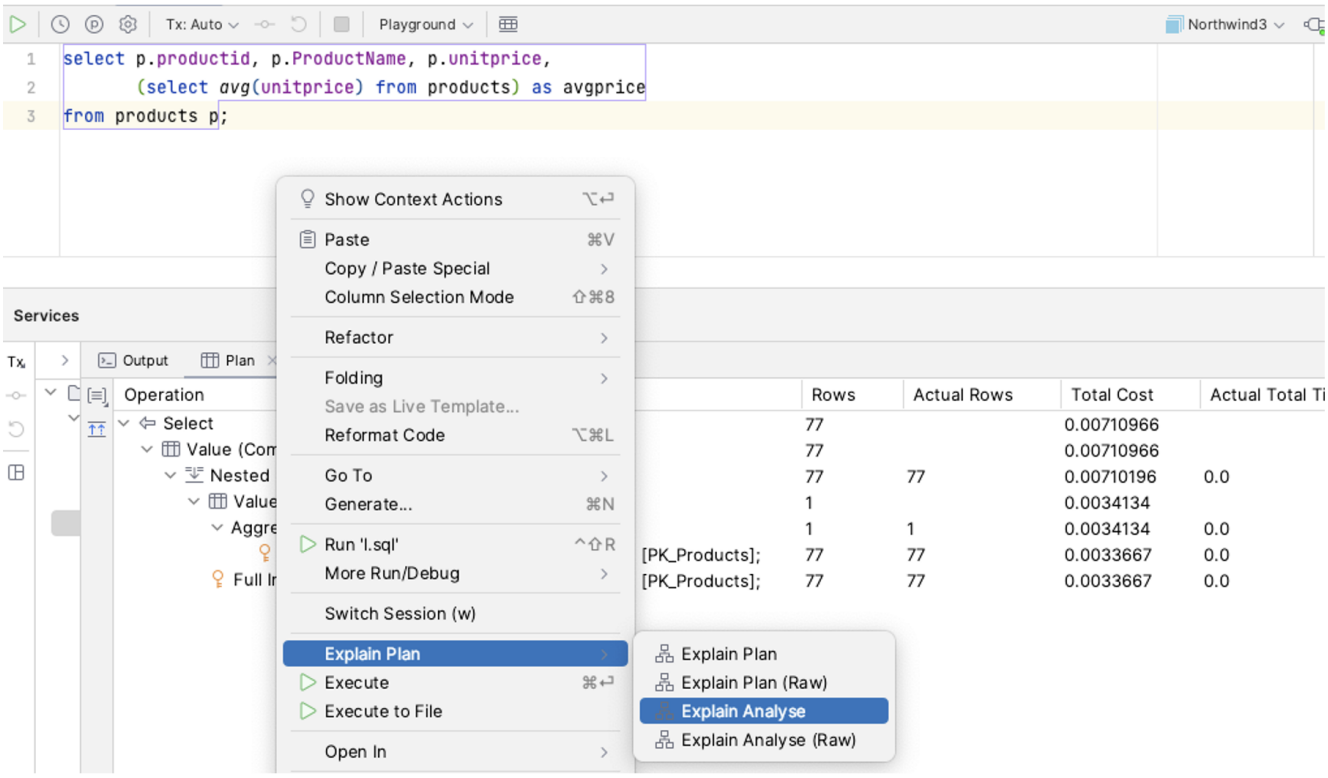

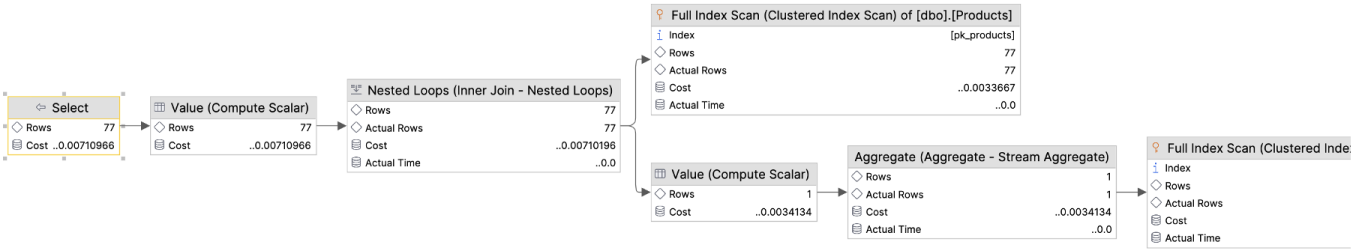

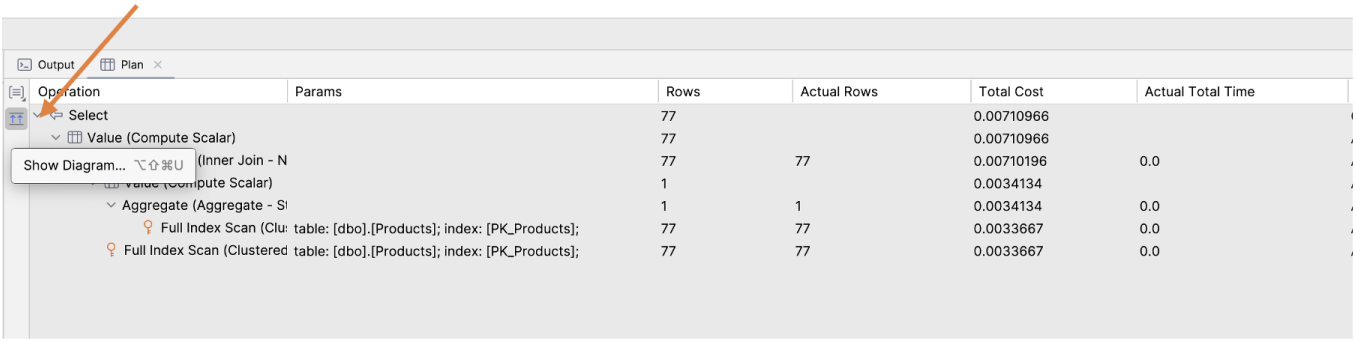

> Wyniki:

```
select productid, productname, unitprice,
(select avg(unitprice) from products) as avgprice
from products p;
```

```sql
select productid, productname, unitprice,
avg(unitprice) over () as avgprice
from products;
```

```sql
select p.productid, p.productname, p.unitprice, avg(a.unitprice) as
avgprice
from products p
cross join products a
group by p.productid, p.productname, p.unitprice;
```

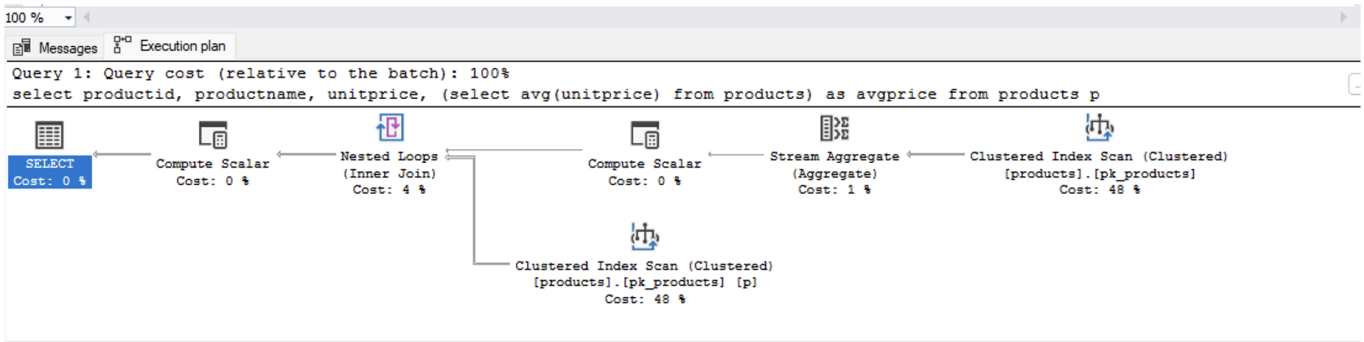

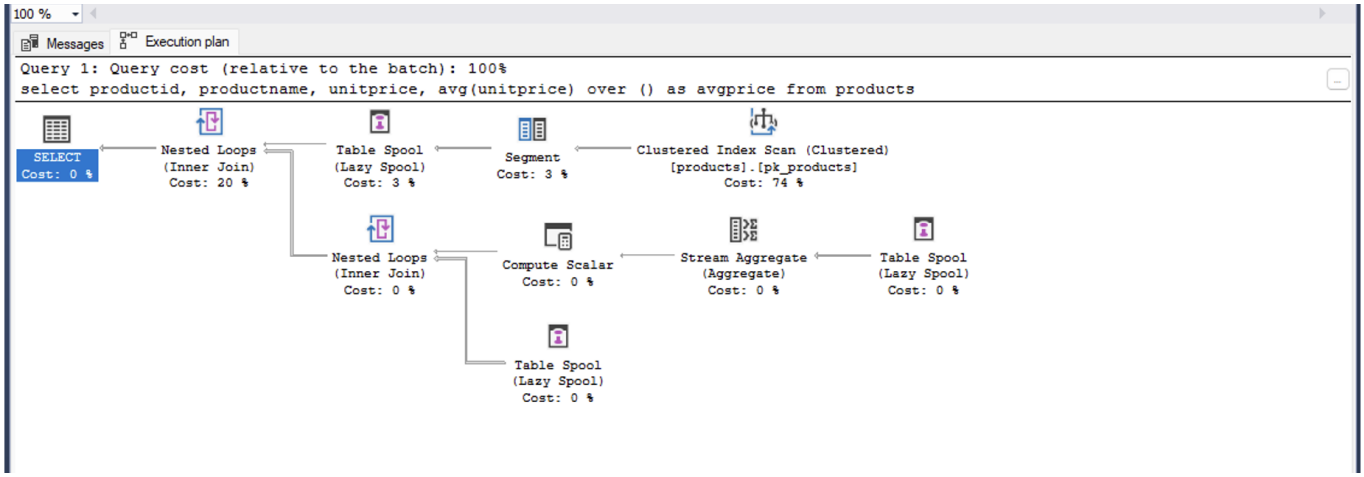

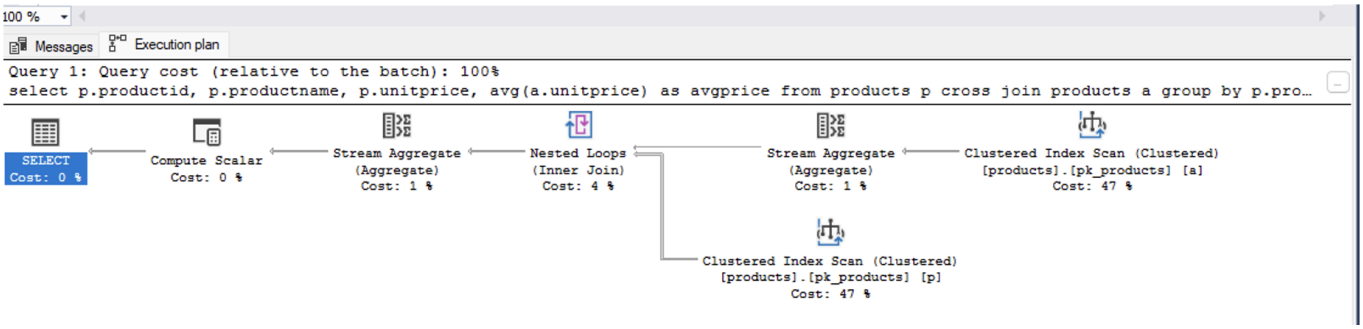

- MS SQL Server:
    - główny koszt we wszystkich zapytaniach to Clustered Index Scan

    - podzapytanie i cross join wykonują dwa Index Scan, a funkcja okna tylko jeden
    - Subquery:
        - dwa skany(dla AVG i dla głównych danych)
        - Wynik AVG przechodzi przez Compute Scalar do każdego wiersza.
    - Window func:
        - jeden skan: AVG i dane główne liczone razem.
    - Cross Join
        - dwa skany: połączone są przez Nested Loop
        - dwie agregacje
- POSTGRES:
    - główny koszt to Seq Scan (pełny skan tabeli products)
    - subquery i cross join wykonują dwa Seq Scan, a window function tylko jeden
    - Subquery:
        - są dwa skany (dla AVG i dla głównego SELECT)
        - jest osobny Aggregate dla obliczenia średniej
    - Window func:
        - jest jeden skan
    - Cross Join:
        - Nested Loop łączy dwa skany
        - jest agregacja na dużym zbiorze danych
- SQLITE:
    - główną operacją w każdym zapytaniu jest Full Scan
    - Subquery:
        - jest blok Subquery
        - wykorzystuje Full Scan
    - Window func:
        - występuje operacja CO-ROUTINE
        - wykorzystuje Full Scan
    - Cross Join:
        - dwa Full Scan

We wszystkich analizowanych systemach najbardziej efektywne jest użycie funkcji okna. Najmniej efektywne jest wykorzystanie CROSS JOIN. Powoduje on łączenie każdego wiersza z każdym (Nested Loop), czyli zwiększa się liczby operacji i kosztu.

Zadanie 4

Baza: Northwind, tabela products

Napisz polecenie, które zwraca: id produktu, nazwę produktu, cenę produktu, średnią cenę produktów w kategorii, do której należy dany produkt. Wyświetl tylko pozycje (produkty) których cena jest większa niż średnia cena.

Napisz polecenie z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj zapytania. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

> Wyniki:

```
select p.productid, p.productname, p.unitprice,
       (
           select avg(x.unitprice)
           from products x
           where x.categoryid = p.categoryid
       ) as avg_category_price
from products p
where p.unitprice > (
    select avg(x.unitprice)
    from products x
    where x.categoryid = p.categoryid
);
```

```
select *
from (
    select p.productid, p.productname, p.unitprice,
           avg(p.unitprice) over (partition by p.categoryid) as
avg_category_price
    from products p
) t
where t.unitprice > t.avg_category_price;
```

```
select p.productid, p.productname, p.unitprice, avg(x.unitprice) as
avg_category_price
from products p
```

```
  left join products x
    on x.categoryid = p.categoryid
  group by p.productid, p.productname, p.unitprice
  having p.unitprice > avg(x.unitprice);
```

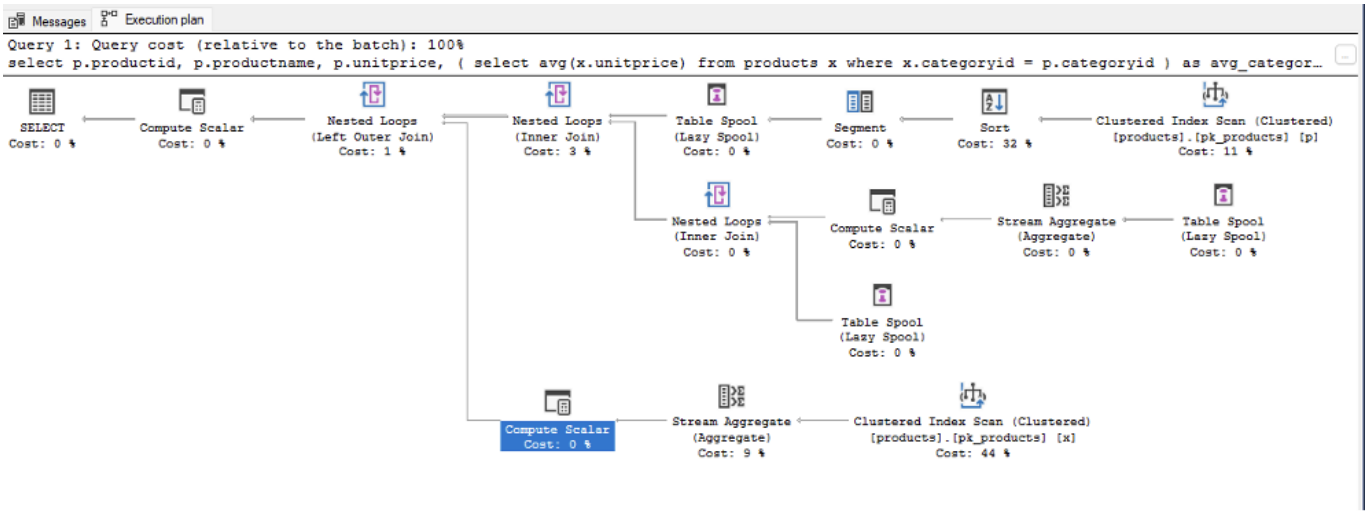

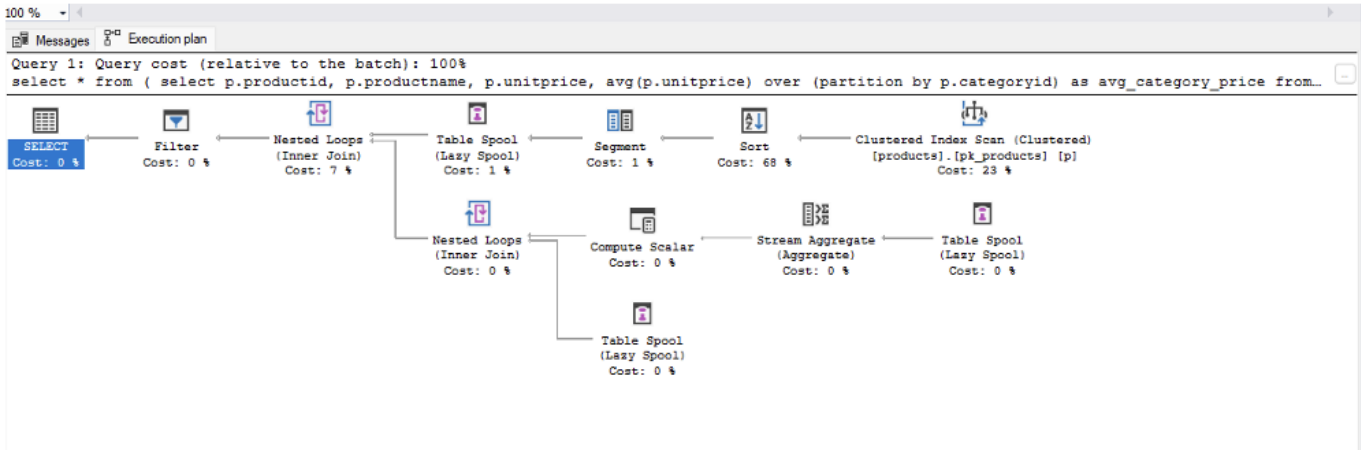

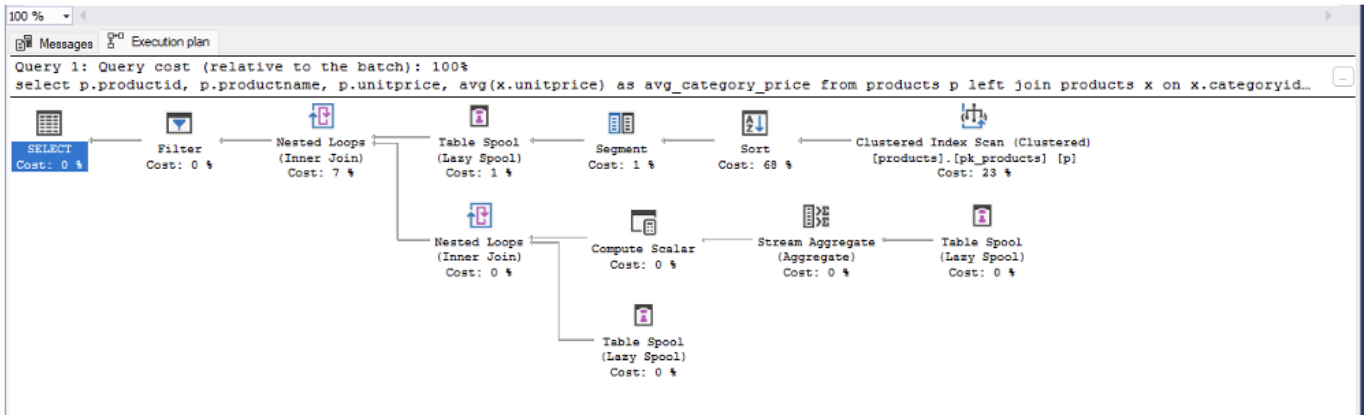

Najlepszym rozwiązaniem jest funkcja okna, bo pozwala policzyć średnią bez robienia osobnego zapytania i dodatkowego skanowania tabeli. Mimo że pojawiają się jakieś dodatkowe operacje jak sort czy spool, to i tak jest to bardziej opłacalne niż ponowne czytanie danych.

Podzapytanie jest mniej wydajne, bo widać, że tabela jest skanowana więcej niż raz: raz do głównego zapytania i drugi raz do policzenia średniej. Do tego dochodzi jeszcze osobna agregacja, więc robi się więcej operacji.

Najgorzej wypada rozwiązanie z join, bo łączy dane przez Nested Loop i potem robi agregację na większym zbiorze. To powoduje więcej pracy dla silnika i bardziej rozbudowany plan wykonania.

Zadanie 5

Oryginalna baza Northwind jest bardzo mała. Warto zaobserwować działanie na nieco większym zbiorze danych.

Baza Northwind3 zawiera dodatkową tabelę product_history

- 2,2 mln wierszy

Bazę Northwind3 można pobrać z moodle (zakładka - Backupy baz danych)

Można też wygenerować tabelę product_history przy pomocy skryptu

Skrypt dla SQL Srerver

Stwórz tabelę o następującej strukturze:

```
create table product_history(
   id int identity(1,1) not null,
   productid int,
   productname varchar(40) not null,
   supplierid int null,
   categoryid int null,
   quantityperunit varchar(20) null,
   unitprice decimal(10,2) null,
   quantity int,
   value decimal(10,2),
   date date,
 constraint pk_product_history primary key clustered
    (id asc )
)
```

Wygeneruj przykładowe dane:

Dla 30000 iteracji, tabela będzie zawierała nieco ponad 2mln wierszy (dostostu ograniczenie do możliwości swojego komputera)

Skrypt dla SQL Srerver

```
declare @i int
set @i = 1
while @i <= 30000
begin
    insert product_history
    select productid, ProductName, SupplierID, CategoryID,
```

```
          QuantityPerUnit,round(RAND()*unitprice + 10,2),
          cast(RAND() * productid + 10 as int), 0,
          dateadd(day, @i, '1940-01-01')
     from products
     set @i = @i + 1;
end;

update product_history
set value = unitprice * quantity
where 1=1;
```

Skrypt dla Postgresql

```
create table product_history(
   id int generated always as identity not null
       constraint pkproduct_history
            primary key,
   productid int,
   productname varchar(40) not null,
   supplierid int null,
   categoryid int null,
   quantityperunit varchar(20) null,
   unitprice decimal(10,2) null,
   quantity int,
   value decimal(10,2),
   date date
);
```

Wygeneruj przykładowe dane:

Skrypt dla Postgresql

```
do $$
begin
  for cnt in 1..30000 loop
    insert into product_history(productid, productname, supplierid,
           categoryid, quantityperunit,
           unitprice, quantity, value, date)
    select productid, productname, supplierid, categoryid,
           quantityperunit,
           round((random()*unitprice + 10)::numeric,2),
           cast(random() * productid + 10 as int), 0,
           cast('1940-01-01' as date) + cnt
    from products;
  end loop;
end; $$;

update product_history
```

```
set value = unitprice * quantity
where 1=1;
```

Wykonaj polecenia: `select count(*) from product_history`, potwierdzające wykonanie zadania

> Wyniki:

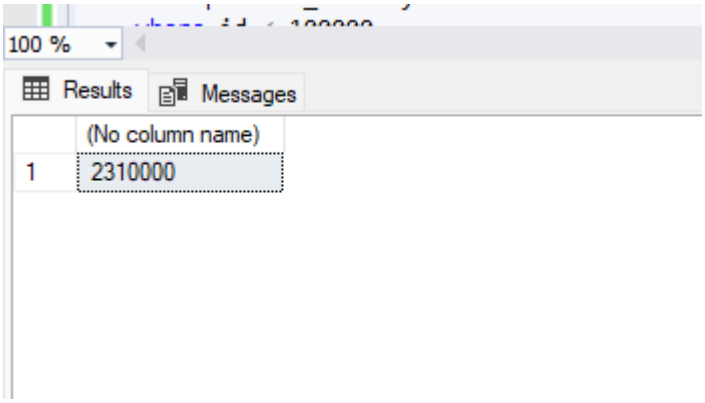

Zadanie 6

Baza: Northwind, tabela product_history

Napisz polecenie, które zwraca: id pozycji, id produktu, nazwę produktu, id_kategorii, cenę produktu, średnią cenę produktów w kategorii do której należy dany produkt. Wyświetl tylko pozycje (produkty) których cena jest większa niż średnia cena.

W przypadku długiego czasu wykonania ogranicz zbiór wynikowy do kilkuset/kilku tysięcy wierszy

pomocna może być konstrukcja `with`

```
with t as (

....
)
select * from t
where id between ....
```

Napisz polecenie z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj zapytania. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

> Wyniki:

```
select *
from (
```

```
    select
    id,
    productid,
    productname,
    categoryid,
    unitprice,
    avg(unitprice) over (partition by categoryid) as avg_price_in_category
    from product_history
    where id < 100000
) t
where unitprice > avg_price_in_category;
```

```
with t as (
    select *
    from product_history
    where id < 20000
)
select
    p.id,
    p.productid,
    p.productname,
    p.categoryid,
    p.unitprice,
    avg(pp.unitprice) as avg_price_in_category
from t p
join t pp on p.categoryid = pp.categoryid
group by
    p.id, p.productid, p.productname, p.categoryid, p.unitprice
having p.unitprice > avg(pp.unitprice)
order by p.id;
```

```
with t as (
    select *
    from product_history
    where id < 100000
)
select *
from (
    select
        id,
        productid,
        productname,
        categoryid,
        unitprice,
        avg(unitprice) over (partition by categoryid) as
avg_price_in_category
    from t
) x
```

```
where unitprice > avg_price_in_category
order by id;
```

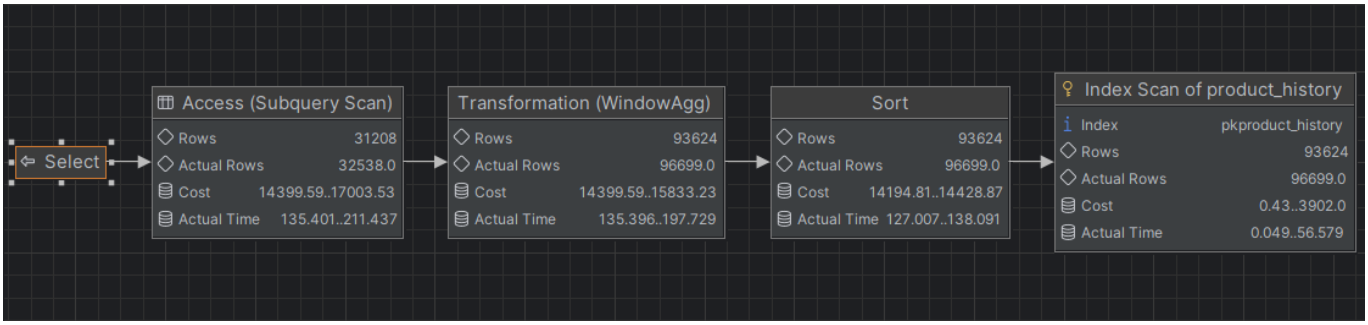

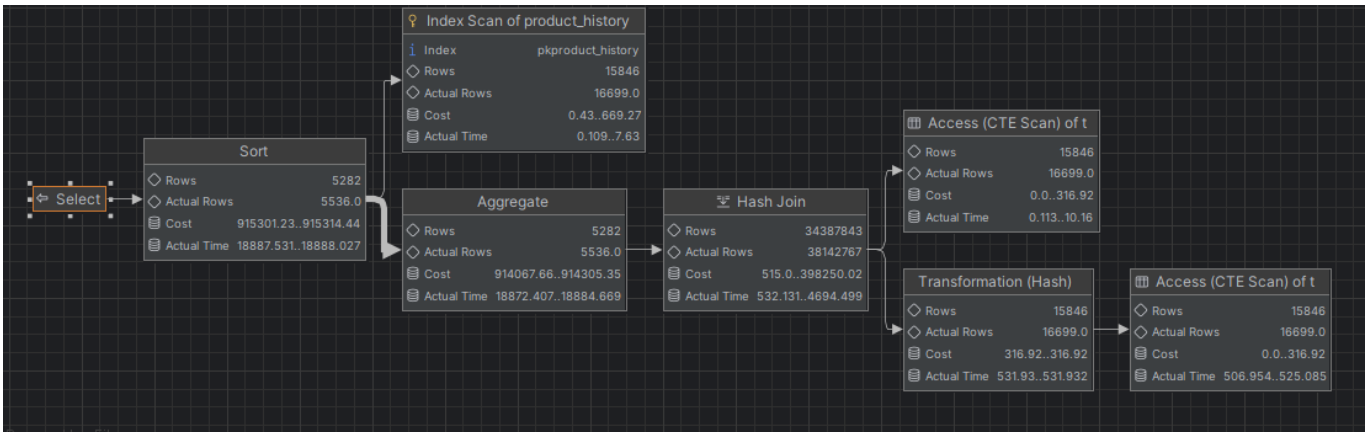

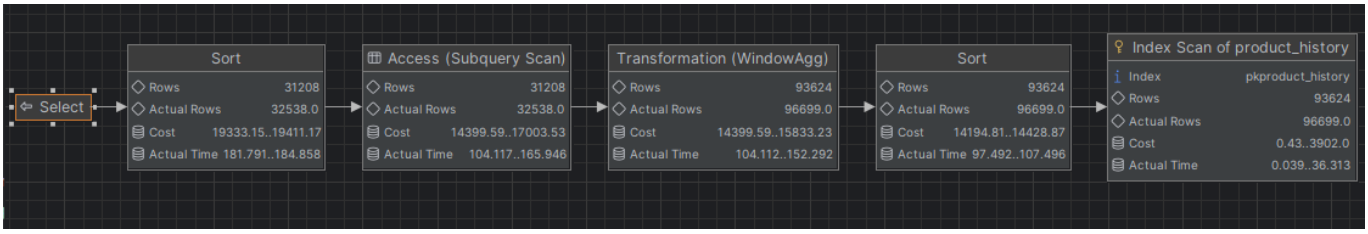

Ze względu na długi czas wykonania zapytań ograniczyliśmy liczbę wierszy.

Podzapytanie i funkcja okna dawały podobne wyniki czasowe. Największa różnica była widoczna w przypadku zapytania z join. W PostgreSQL czas wykonania był znacznie dłuższy, ponieważ wykorzystywany był Hash Join oraz agregacja na dużym zbiorze danych. W SQL Server to samo zapytanie wykonywało się szybciej. Wynika to z zastosowania innych mechanizmów.

---

zadanie	pkt
1	1
2	1
3	1
4	1
5	1
6	2

```
razem:      7
```